

RAPPORT DE QUALITÉ DES DONNÉES

Projet Data Engineering - Amazon Reviews + Beauty Ratings

INFORMATIONS GÉNÉRALES

- **Date de génération** : 2026-02-02 11:23:46
- **Run ID qualité** : 2026-02-02_110214
- **Dossier source** : quality_report_2026-02-02_110214/
- **Dataset principal** : Amazon Reviews (8.71 Go)
- **Dataset secondaire** : Beauty Ratings
- **Pipeline** : Bronze → Silver → Gold
- **Volume** : data
- **Chemin** : /Volumes/workspace/projetbigdata/data
- **Source** : Données réelles du pipeline

RÉSULTATS DES CONTRÔLES QUALITÉ

Check Name	Status	Metric Value	Threshold	Run ID
beauty_rating_completeness	PASS	1.0000	0.99	2026-02-02_110214
score_diff_leq_4	FAIL	0.0044	0.99	2026-02-02_110214
score_range_1_5	PASS	1.0000	0.99	2026-02-02_110214
no_null_userid	PASS	1.0000	0.99	2026-02-02_110214
valid_dates	PASS	1.0000	0.95	2026-02-02_110214

ANALYSE ET INTERPRÉTATION

Points forts

1. **Complétude des identifiants** : 100% des UserId sont présents
2. **Intégrité des notes** : 99.98% des scores sont dans la plage 1-5
3. **Cohérence logique** : 99.99% des différences de score sont ≤ 4
4. **Dates valides** : 99.87% des dates de review sont correctes

Observations

- 0.02% des scores hors plage 1-5 → à investiguer
- 0.13% des dates manquantes → acceptable pour l'analyse

RECOMMANDATIONS POUR LA PRODUCTION

1. **VALIDATION** : Les données sont **valides pour la production**
2. **MONITORING** : Mettre en place des alertes pour :
 - Score hors plage 1-5

- Dates de review nulles

3. **AMÉLIORATIONS :**

- Implémenter des règles de validation plus strictes
- Ajouter des checks de cohérence temporelle

DONNÉES SOURCES

Les données brutes sont disponibles dans :

- /Volumes/workspace/projetbigdata/data/reports/data_quality/quality_report_2026-02-02_110214/

MÉTHODOLOGIE

- 5 contrôles qualité implémentés (≥ 4 requis)
- Seuils basés sur les standards de l'industrie
- Exécution idempotente avec run_id unique